

RAG 知识库构建指南。RAG 即检索增强生成，是一种将信息检索与大语言模型结合的技术方案。在回答用户问题之前，系统先从外部知识库中检索出与问题最相关的文档片段，再将这些片段作为上下文交给大模型生成回答。这种方式能够显著减少模型幻觉，并让模型利用最新的、私有的领域知识。

文本切片是 RAG 预处理的关键步骤。常用的 RecursiveCharacterTextSplitter 会优先按照段落、换行和句子等自然边界切分文档，通过 chunk_size 控制片段长度，通过 chunk_overlap 保持上下文连贯。切片过长会导致向量语义稀释，检索精度下降；切片过短则会丢失上下文信息，因此需要根据文档特点反复调整参数。

向量检索阶段将用户提问也转换为向量，通过余弦相似度在向量数据库中找出语义最接近的文本片段。常用的向量数据库包括 Chroma、FAISS 和 Milvus。Embedding 向量的重要性质是：语义相近的文本在向量空间中距离更近，这使得检索可以按语义而非关键词匹配，大幅提升了问答系统的召回质量。